

# Probabilidade (PPGECD000000001)

## Programa de Pós-Graduação em Estatística e Ciência de Dados (PGECD)

### Sessão 6

Raydonal Ospina

Departamento de Estatística  
Universidade Federal da Bahia  
Salvador/BA

# Variáveis Aleatórias Multidimensionais

Muitas vezes estamos interessados na descrição probabilística de mais de um característico numérico de um experimento aleatório. Por exemplo, podemos estar interessados na distribuição de alturas e pesos de indivíduos de uma certa classe. Para tanto precisamos estender a definição de variável aleatória para o caso multidimensional.

## Definição 1

Seja  $(\Omega, \mathcal{A}, P)$  um espaço de probabilidade. Uma função  $\vec{X} : \Omega \rightarrow \mathbb{R}^n$  é chamada de um vetor aleatório se para todo evento  $B$  Boreliano de  $\mathbb{R}^n$ ,  $\vec{X}^{-1}(B) \in \mathcal{A}$ .

Onde um evento é Boreliano em  $\mathbb{R}^n$  pertence a menor  $\sigma$ -álgebra que contém todas as regiões da seguinte forma:  $C_{\vec{a}} = \{(X_1, X_2, \dots, X_n) : X_i \leq a_i, 1 \leq i \leq n\}$ .

Dado um vetor aleatório  $\vec{X}$ , pode-se definir uma probabilidade induzida  $P_{\vec{X}}$  no espaço mensurável  $(\mathbb{R}^n, \mathcal{B}^n)$  da seguinte maneira: para todo  $A \in \mathcal{B}^n$ , definimos  $P_{\vec{X}}(A) = P(\vec{X}^{-1}(A))$ . Por definição de vetor aleatório, tem-se que  $\vec{X}^{-1}(A) \in \mathcal{A}$ , então  $P_{\vec{X}}$  está bem definida. Para um vetor aleatório  $\vec{X}$ , uma maneira simples e básica de

descrever a probabilidade induzida  $P_{\vec{X}}$  é utilizando sua *função de distribuição acumulada conjunta*.

# Função de Distribuição Acumulada Conjunta

## Definição 2

A função de distribuição acumulada conjunta de um vetor aleatório  $\vec{X}$ , representada por  $F_{\vec{X}}$  ou simplesmente por  $F$ , é definida por

$$\begin{aligned} F_{\vec{X}}(\vec{x}) &= P(C_{\vec{x}}) \\ &= P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n), \forall \vec{x} \in \mathbb{R}^n. \end{aligned}$$

## Propriedades

A função de distribuição acumulada  $F_{\vec{X}}$  satisfaz as seguintes propriedades:

**F1.** Se  $x_i \leq y_i, \forall i \leq n$ , então  $F_{\vec{X}}(\vec{x}) \leq F_{\vec{X}}(\vec{y})$ . Note que

$$x_i \leq y_i \forall i \leq n \Rightarrow C_{\vec{x}} \subseteq C_{\vec{y}} \Rightarrow P(C_{\vec{x}}) \leq P(C_{\vec{y}}) \Rightarrow F_{\vec{X}}(\vec{x}) \leq F_{\vec{X}}(\vec{y}).$$

**F2.**  $F(x_1, x_2, \dots, x_n)$  é contínua a direita em cada uma das variáveis. Por exemplo, se  $y_m \downarrow x_1$ , então

$$F(y_m, x_2, \dots, x_n) \downarrow F(x_1, x_2, \dots, x_n), \text{ quando } m \rightarrow \infty.$$

F3a. Se para algum  $i \leq n$   $x_i \rightarrow -\infty$ , então  $C_{\vec{x}}$  decresce monotonicamente para o conjunto vazio  $\emptyset$ . Logo, pela continuidade monotônica de probabilidade, temos que

$$\lim_{x_i \rightarrow -\infty} F_{\vec{x}}(\vec{x}) = 0.$$

F3b. Se  $x_i \rightarrow \infty$ , então  $C_{\vec{x}}$  cresce monotonicamente para o conjunto

$$\{X_1 \leq x_1, \dots, X_{i-1} \leq x_{i-1}, X_{i+1} \leq x_{i+1}, \dots, X_n \leq x_n\},$$

ou seja a restrição em  $X_i$  é removida. Então, podemos escrever

$$\begin{aligned} \lim_{x_i \rightarrow \infty} F_{\vec{x}}(\vec{x}) \\ = F_{X_1, \dots, X_{i-1}, X_{i+1}, \dots, X_n}(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n). \end{aligned}$$

Portanto, a função de distribuição acumulada conjunta de  $X_1, \dots, X_{n-1}$  pode ser facilmente determinada da função de distribuição acumulada conjunta de  $X_1, \dots, X_n$  fazendo  $x_n \rightarrow \infty$ . Observe que *funções de distribuição acumuladas conjuntas de ordem maiores determinam as de ordem menores, mas o contrário não é verdadeiro*. Em particular, temos que

$$\lim_{\vec{x} \rightarrow \infty} F_{\vec{x}}(\vec{x}) = 1.$$

## Distribuição marginal

A função de distribuição acumulada de  $X_i$  que se obtém a partir da função acumulada conjunta de

$X_1, \dots, X_n$  fazendo  $x_j \rightarrow \infty$  para  $j \neq i$  é conhecida como *função de distribuição marginal* de  $X_i$ .

O próximo exemplo mostra que para  $n \geq 2$  as propriedades F1, F2, e F3 não são suficientes para que  $F$  seja uma função de distribuição.

### Exemplo 1

Seja  $F_0 : \mathbb{R}^2 \rightarrow \mathbb{R}$  uma função definida no plano tal que  $F_0(x, y) = 1$  se  $x \geq 0, y \geq 0$ , e  $x + y \geq 1$ , e  $F_0(x, y) = 0$ , caso contrário. É claro que F1, F2, e F3 são satisfeitas, mas  $F_0$  não é função de distribuição de nenhum vetor aleatório  $(X, Y)$ . Se fosse, teríamos uma contradição

$$\begin{aligned} 0 &\leq P(0 < X \leq 1, 0 < Y \leq 1) \\ &= F_0(1, 1) - F_0(1, 0) - F_0(0, 1) + F_0(0, 0) \\ &= 1 - 1 - 1 + 0 = -1 \end{aligned}$$

## Tipos de Vetores Aleatórios

Os tipos discretos e contínuos de variáveis aleatórias têm os seguintes análogos no caso multivariado.

- (a) Se  $\vec{X}$  for um vetor aleatório discreto, ou seja assumir um número enumerável de valores  $\{\vec{x}_1, \vec{x}_2, \dots\}$ , podemos definir uma função de probabilidade de massa conjunta,  $p$  tal que

- ▶  $p(\vec{x}_i) \geq 0$ .
- ▶  $\sum_{i=1}^{\infty} p(\vec{x}_i) = 1$ .

Neste caso, pode-se definir a *função probabilidade de massa marginal* de  $X_i$  como sendo

$$p_{X_i}(x_i) = \sum_{x_1} \cdots \sum_{x_{i-1}} \sum_{x_{i+1}} \cdots \sum_{x_n} p(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n).$$

- (b) Seja  $\vec{X} = (X_1, \dots, X_n)$  um vetor aleatório e  $F$  sua função de distribuição. Se existe uma função  $f(x_1, \dots, x_n) \geq 0$  tal que

$$F(x_1, \dots, x_n) = \int_{-\infty}^{x_n} \cdots \int_{-\infty}^{x_1} f(t_1, \dots, t_n) dt_1 \dots dt_n,$$
$$\forall (x_1, \dots, x_n) \in \mathbb{R}^n,$$

então  $f$  é chamada de densidade conjunta das variáveis aleatórias  $X_1, \dots, X_n$ , e neste caso, dizemos que  $\vec{X}$  é (absolutamente) contínuo. Neste caso, define-se a *densidade marginal* de  $X_i$  como sendo

$$f_{X_i}(x_i) = \int_{\mathbb{R}^{n-1}} \cdots \int f(x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_n) dx_1 \dots dx_{i-1} dx_{i+1} \dots dx_n.$$

## Comentário: Distribuição condicional de $X$ dada $Y$ discreta

Seja  $X$  uma variável aleatória no espaço de probabilidade  $(\Omega, \mathcal{A}, P)$ , e seja  $A$  um evento aleatório tal que  $P(A) > 0$ . Usando o conceito de probabilidade condicional, podemos definir a distribuição condicional de  $X$  dado o evento  $A$  por

$$P(X \in B|A) = \frac{P([X \in B] \cap A)}{P(A)},$$

para  $B$  boreliano. Pode-se verificar facilmente que isto define uma probabilidade nos borelianos verificando-se os axiomas de Kolmogorov. Podemos interpretar a distribuição condicional de  $X$  dado  $A$  como a nova distribuição que se atribui a  $X$  quando sabe-se da ocorrência do evento  $A$ . A função de distribuição associada à distribuição condicional é chamada função distribuição condicional de  $X$  dado  $A$ :

$$F_X(x|A) = P(X \leq x|A).$$

Agora suponhamos que os eventos aleatórios  $A_1, A_2, \dots$  formem uma partição (finita ou enumerável) de  $\Omega$ . Pelo Teorema da Probabilidade Total, temos

$$P(X \in B) = \sum_n P(A_n)P(X \in B|A_n), \forall B \in \mathcal{B},$$

e

$$\begin{aligned} F_X(x) &= P(X \leq x) = \sum_n P(A_n)P(X \leq x|A_n) \\ &= \sum_n P(A_n)F_X(x|A_n), \forall x. \end{aligned}$$



Em outras palavras, a distribuição de  $X$  (resp., função de distribuição) é uma média ponderada da distribuição condicional (resp., função de distribuição condicional) de  $X$  dado  $A_n$ , onde os pesos são as probabilidades dos membros  $A_n$  da partição.

Consideremos agora o caso em que a partição do espaço amostral é gerada por uma variável aleatória discreta. Para tanto, seja  $Y$  uma variável aleatória discreta em  $(\Omega, \mathcal{A}, P)$ , tomando somente os valores  $y_1, y_2, \dots$ . Então, os eventos  $A_n = [Y = y_n]$  formam uma partição de  $\Omega$ . Neste caso, a distribuição

$$P(X \in B | Y = y_n) = P(X \in B | A_n),$$

para  $B$  boreliano, é chamada de distribuição condicional de  $X$  dado que  $Y = y_n$ , e valem as fórmulas

$$P(X \in B) = \sum_n P(Y = y_n) P(X \in B | Y = y_n), \quad B \text{ boreliano}$$

$$F_X(x) = \sum_n P(Y = y_n) F_X(x | Y = y_n).$$

# Independência entre Variáveis Aleatórias

Sejam  $X_1, X_2, \dots, X_n$  variáveis aleatórias definidas no mesmo espaço de probabilidade  $(\Omega, \mathcal{A}, P)$ . Informalmente, as variáveis aleatórias  $X_i$ 's são independentes se, e somente se, quaisquer eventos determinados por qualquer grupo de variáveis aleatórias distintas são independentes. Por exemplo,  $[X_1 < 5]$ ,  $[X_2 > 9]$ , e  $0 < X_5 \leq 3$  são independentes. Formalmente,

## Definição 3

*Um conjunto de variáveis aleatórias  $\{X_1, \dots, X_n\}$  é mutuamente independente se, e somente se, para quaisquer eventos borelianos  $A_1, \dots, A_n$ ,*

$$P(X_1 \in A_1, \dots, X_n \in A_n) = \prod_{i=1}^n P(X_i \in A_i).$$

O próximo teorema estabelece três critérios para provar que um conjunto de variáveis aleatórias é mutuamente independente.

## Teorema 1

As seguintes condições são necessárias e suficientes para testar se um conjunto  $\{X_1, \dots, X_n\}$  de variáveis aleatórias é mutuamente independente:

(a)  $F_{\vec{X}}(\vec{x}) = \prod_{i=1}^n F_{X_i}(x_i).$

(b) Se  $\vec{X}$  for um vetor aleatório discreto,

$$p_{\vec{X}}(\vec{x}) = \prod_{i=1}^n p_{X_i}(x_i).$$

(c) Se  $\vec{X}$  for um vetor aleatório contínuo,

$$f_{\vec{X}}(\vec{x}) = \prod_{i=1}^n f_{X_i}(x_i), \forall (x_1, \dots, x_n) \in \mathbb{R}^n.$$

## Demonstração

Para parte (a), note que se  $\{X_1, \dots, X_n\}$  são variáveis aleatórias mutuamente independentes, então

$$\begin{aligned} F_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) &= P(X_1 \leq x_1, \dots, X_n \leq x_n) \\ &= \prod_{i=1}^n P(X_i \leq x_i) = \prod_{i=1}^n F_{X_i}(x_i), \forall (x_1, \dots, x_n) \end{aligned}$$

A prova da suficiência da parte (a) será omitida pois envolve argumentos de teoria da medida. Para parte (b), se  $\{X_1, \dots, X_n\}$  são variáveis aleatórias mutuamente independentes, então

$$\begin{aligned} p_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) &= P(X_1 = x_1, \dots, X_n = x_n) \\ &= \prod_{i=1}^n P(X_i = x_i) = \prod_{i=1}^n p_{X_i}(x_i), \forall (x_1, \dots, x_n) \end{aligned}$$

Reciprocamente, se a função de probabilidade de massa conjunta fatora e se  $\{x_{i1}, x_{i2}, \dots, x_{in}, \dots\}$  são os possíveis valores assumidos pela variável aleatória  $X_i$ , temos que

$$\begin{aligned} & P(X_1 \in B_1, X_2 \in B_2, \dots, X_n \in B_n) \\ &= \sum_{i: x_{1i} \in B_1} \cdots \sum_{i: x_{ni} \in B_n} P(X_1 = x_{1i}, \dots, X_n = x_{ni}) \\ &= \sum_{i: x_{1i} \in B_1} \cdots \sum_{i: x_{ni} \in B_n} p_{X_1, \dots, X_n}(x_{1i}, \dots, x_{ni}) \\ &= \sum_{i: x_{1i} \in B_1} \cdots \sum_{i: x_{ni} \in B_n} \prod_{j=1}^n p_{X_j}(x_{ji}) = \prod_{j=1}^n P(X_j \in B_j) \end{aligned}$$

A parte (c) é uma consequência direta da parte (a) e da definição de função de densidade. Omitimos os detalhes.

## Nota 1

É fácil observar que utilizando, a definição de probabilidade condicional que se  $X$  e  $Y$  são independentes, então para todo  $A$  e  $B$  boreliano tal que  $P(Y \in B) > 0$ :

$$P(X \in A | Y \in B) = P(X \in A),$$

ou seja, se  $X$  e  $Y$  são independentes o conhecimento do valor de  $Y$  não altera a descrição probabilística de  $X$ .

# Exemplos de Distribuições Multivariadas

## A Distribuição Multinomial

Esta distribuição pode ser considerada como uma generalização da distribuição binomial. Considere um experimento aleatório qualquer e suponha que o espaço amostral deste experimento é particionado em  $k$  eventos  $\{A_1, A_2, \dots, A_k\}$ , onde o evento  $A_i$  tem probabilidade  $p_i$ . Suponha que se repita este experimento  $n$  vezes de maneira independente e seja  $X_i$  o número de vezes que o evento  $A_i$  ocorreu nestas  $n$  repetições. Então,

$$\begin{aligned} P(X_1 = n_1, X_2 = n_2, \dots, X_k = n_k) \\ = \frac{n!}{n_1! n_2! \dots n_k!} p_1^{n_1} p_2^{n_2} \dots p_k^{n_k}, \end{aligned} \quad (1)$$

onde  $\sum_{i=1}^k n_i = n$ . (Relembre que o número de maneiras de arranjar  $n$  objetos,  $n_1$  dos quais é de uma espécie,  $n_2$  dos quais é de uma segunda espécie,  $\dots$ ,  $n_k$  dos quais são de uma  $k$ -ésima espécie é dado pelo coeficiente multinomial  $\frac{n!}{n_1! n_2! \dots n_k!}$ .)

# Exemplos de Distribuições Multivariadas

## A Distribuição Normal Bivariada

O vetor aleatório  $(X, Y)$  possui distribuição normal bivariada quando tem densidade dada por

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} \\ \times \exp\left\{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_1}{\sigma_1}\right)^2 - 2\rho\left(\frac{x-\mu_1}{\sigma_1}\right)\left(\frac{y-\mu_2}{\sigma_2}\right) + \left(\frac{y-\mu_2}{\sigma_2}\right)^2\right]\right\},$$

onde  $\sigma_1 > 0, \sigma_2 > 0, -1 < \rho < 1, \mu_1 \in \mathbb{R}, \mu_2 \in \mathbb{R}$ .

Se  $\rho = 0$ , esta densidade fatora e temos que  $X$  e  $Y$  são independentes. Se  $\rho \neq 0$ , esta densidade não fatora e  $X$  e  $Y$  não são independentes.

# Funções de Variáveis Aleatórias

- Muitas vezes sabemos a distribuição de probabilidade que descreve o comportamento de uma variável aleatória  $X$  definida no espaço mensurável  $(\Omega, \mathcal{A})$ , mas estamos interessados na descrição de uma função  $Y = H(X)$ .
- Nosso problema é determinar  $P(Y \in A)$ , onde  $A$  é um evento Boreliano, dado  $P_X$ . Para determinarmos esta probabilidade, estaremos interessados na imagem inversa da função  $H$ , ou seja, a probabilidade do evento  $\{Y \in A\}$  será por definição igual a probabilidade do evento  $\{X \in H^{-1}(A)\}$ , onde  $H^{-1}(A) = \{x \in \mathbb{R} : H(x) \in A\}$ .
- Precisamos restringir  $H$  tal que  $H^{-1}(A)$  seja um evento boreliano para todo  $A$  boreliano, caso contrário não poderemos determinar  $P(\{X \in H^{-1}(A)\})$ ; uma função que satisfaz esta condição é conhecida como *mensurável com respeito a  $\mathcal{A}$  e  $\mathcal{B}$* . Note que  $Y$  também pode ser vista como uma função do espaço amostral  $\Omega$ ,  $Y(\omega) = H(X(\omega))$  para todo  $\omega \in \Omega$ .
- Visto dessa maneira  $Y$  é uma variável aleatória definida em  $(\Omega, \mathcal{A})$ , pois para todo boreliano  $A$ ,  $Y^{-1}(A) = X^{-1}(H^{-1}(A))$  e como por suposição  $H^{-1}(A)$  é boreliano e  $X$  é uma variável aleatória, temos que  $X^{-1}(H^{-1}(A)) \in \mathcal{A}$  e portanto satisfaz a definição de uma variável aleatória.



# Funções de Variáveis Aleatórias

## Caso Discreto

Neste caso, para qualquer função  $H$ , temos que  $Y = H(X)$  é uma variável aleatória discreta.

Suponha que  $X$  assumam os valores  $x_1, x_2, \dots$  e seja  $H$  uma função real tal que  $Y = H(X)$  assumam os valores  $y_1, y_2, \dots$ . Vamos agrupar os valores que  $X$  assume de acordo com os valores de suas imagens quando se aplica a função  $H$ , ou seja, denotemos por  $x_{i1}, x_{i2}, x_{i3}, \dots$  os valores de  $X$  tal que  $H(x_{ij}) = y_i$  para todo  $j$ . Então, temos que

$$\begin{aligned} P(Y = y_i) &= P(X \in \{x_{i1}, x_{i2}, x_{i3}, \dots\}) \\ &= \sum_{j=1}^{\infty} P(X = x_{ij}) = \sum_{j=1}^{\infty} p_X(x_{ij}), \end{aligned}$$

ou seja, para calcular a probabilidade do evento  $\{Y = y_i\}$ , acha-se o evento equivalente em termos de  $X$ , isto é, todos os valores  $x_{ij}$  de  $X$  tal que  $H(x_{ij}) = y_i$  e somam-se as probabilidades de  $X$  assumir cada um desses valores.

# Funções de Variáveis Aleatórias

## Exemplo 2

Caso Discreto Admita-se que  $X$  tenha os valores possíveis  $1, 2, 3, \dots$  e suponha que  $P(X = n) = (1/2)^n$ . Seja  $Y = 1$  se  $X$  for par e  $Y = -1$  se  $X$  for ímpar. Então, temos que

$$P(Y = 1) = \sum_{n=1}^{\infty} (1/2)^{2n} = \sum_{n=1}^{\infty} (1/4)^n = \frac{1/4}{1 - 1/4} = 1/3.$$

Consequentemente,

$$P(Y = -1) = 1 - P(Y = 1) = 2/3.$$

## Caso Discreto Vetorial

Podemos estender este resultado para uma função de um vetor aleatório  $\vec{X}$  de forma análoga. Neste caso se  $\vec{Y} = H(\vec{X})$ , denotemos por  $\vec{x}_{i1}, \vec{x}_{i2}, \vec{x}_{i3}, \dots$  os valores de  $\vec{X}$  tal que  $H(\vec{x}_{ij}) = \vec{y}_i$  para todo  $j$ . Então, temos que

$$\begin{aligned} P(\vec{Y} = \vec{y}_i) &= P(\vec{X} \in \{\vec{x}_{i1}, \vec{x}_{i2}, \vec{x}_{i3}, \dots\}) \\ &= \sum_{j=1}^{\infty} P(\vec{X} = \vec{x}_{ij}) = \sum_{j=1}^{\infty} p_{\vec{X}}(\vec{x}_{ij}), \end{aligned}$$

ou seja, para calcular a probabilidade do evento  $\{\vec{Y} = \vec{y}_i\}$ , acha-se o evento equivalente em termos de  $\vec{X}$ , isto é, todos os valores  $\vec{x}_{ij}$  de  $\vec{X}$  tal que  $H(\vec{x}_{ij}) = \vec{y}_i$  e somam-se as probabilidades de  $\vec{X}$  assumir cada um desses valores.

# Funções de Variáveis Aleatórias

## Caso Contínuo

Vamos ver agora um exemplo no caso em que  $\tilde{X}$  é contínuo.

### Exemplo 3

Se  $X \sim U[0, 1]$ , qual a distribuição de  $Y = -\log(X)$ ? Como

$$0 < Y < \infty \Leftrightarrow 0 < X < 1$$

e  $P(0 < X < 1) = 1$ , temos  $F_Y(y) = 0, y \leq 0$ . Se  $y > 0$ , então

$$P(Y \leq y) = P(-\log(X) \leq y) = P(X \geq e^{-y}) = 1 - e^{-y},$$

ou seja,  $Y \sim \text{Exp}(1)$ .

# Jacobiano de uma Função

Dado um conjunto de  $n$  equações em  $n$  variáveis  $x_1, \dots, x_n$ ,

$$y_1 = f_1(x_1, \dots, x_n), \dots, y_n = f_n(x_1, \dots, x_n),$$

a matriz Jacobiana é definida por

$$J = \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \dots & \frac{\partial y_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_n}{\partial x_1} & \dots & \frac{\partial y_n}{\partial x_n} \end{pmatrix}$$

O determinante de  $J$  é chamado de *Jacobiano*.

# Jacobiano de uma Função

Pode-se provar que o módulo Jacobiano nos dá a razão entre volumes  $n$ -dimensionais em  $\vec{y}$  e  $\vec{x}$  quando a maior dimensão  $\Delta x_i$  tende a zero. Deste modo, temos que o módulo do Jacobiano aparece quando queremos mudar as variáveis de integração em integrais múltiplas, ou seja, existe um teorema do cálculo que afirma que se  $f : G_0 \rightarrow G$  for uma bijeção entre  $G_0$  e  $G$ ,  $f$  e as derivadas parciais que aparecem na matriz Jacobiana forem funções contínuas em  $G_0$ , e o Jacobiano for diferente de zero para todo  $x \in G_0$

$$\begin{aligned} & \int \cdots \int_A g(y_1, \dots, y_n) dy_1 \cdots dy_n \\ &= \int \cdots \int_{f^{-1}(A)} g(f_1(x_1, \dots, x_n), \dots, f_n(x_1, \dots, x_n)) |J| dx_1 \cdots dx_n, \end{aligned}$$

para qualquer função  $g$  integrável em  $A \subseteq G$ .

Vamos agora utilizar mudança de variáveis para resolver o seguinte exemplo da soma de duas variáveis aleatórias.

# Jacobiano de uma Função

## Exemplo

Suponha que  $(X, Y)$  tenha densidade conjunta  $f(x, y)$  e seja  $Z = X + Y$ . Neste caso,

$$F_Z(z) = P(Z \leq z) = P(X + Y \leq z) = P((X, Y) \in B_z),$$

onde  $B_z = \{(x, y) : x + y \leq z\}$ . Portanto,

$$F_Z(z) = \int_{-\infty}^{\infty} \int_{-\infty}^{z-y} f(x, y) dx dy.$$

# Jacobiano de uma Função

## Exemplo (cont.)

Fazendo a mudança de variáveis  $s = x + y$ ,  $t = y$ , que tem jacobiano igual a 1, temos

$$F_Z(z) = \int_{-\infty}^{\infty} \int_{-\infty}^z f(s - t, t) ds dt = \int_{-\infty}^z \int_{-\infty}^{\infty} f(s - t, t) dt ds.$$

Logo,  $\int_{-\infty}^{\infty} f(s - t, t) dt$  é a densidade da soma  $Z = X + Y$ , ou seja,

$$f_Z(z) = \int_{-\infty}^{\infty} f(z - t, t) dt = \int_{-\infty}^{\infty} f(s, z - s) ds,$$

onde fizemos a troca de variáveis  $s = z - t$  para obter a última expressão.



# Jacobiano de uma Função

## Exemplo (cont.)

Se  $X$  e  $Y$  forem variáveis aleatórias independentes com densidades  $f_X$  e  $f_Y$ , temos que  $f(x, y) = f_X(x)f_Y(y)$ , então,

$$\begin{aligned}f_Z(z) &= \int_{-\infty}^{\infty} f_X(z-t)f_Y(t)dt \\&= \int_{-\infty}^{\infty} f_X(t)f_Y(z-t)dt = f_X * f_Y,\end{aligned}$$

onde  $f_X * f_Y$  é conhecida como a *convolução das densidades*  $f_X$  e  $f_Y$ .

# Jacobiano de uma Função

Vamos agora descrever o método do Jacobiano para funções mais gerais  $H$ . Suponha que  $G_0 \subseteq \mathbb{R}^n$ ,  $G \subseteq \mathbb{R}^n$  sejam regiões abertas, e que  $H : G_0 \rightarrow G$  seja uma bijeção entre  $G_0$  e  $G$ . Logo, existe a função inversa  $H^{-1}$  em  $G$ , de modo que  $\vec{X} = H^{-1} \vec{Y}$ . Suponha ainda que  $f$  é a densidade conjunta de  $\vec{X}$  e que  $P(\vec{X} \in G_0) = 1$ . Se as derivadas parciais de  $H^{-1}$  existirem e o Jacobiano  $J$  de  $H^{-1}$  for diferente de zero para todo  $\vec{y} \in G$ , podemos utilizar o teorema da mudança de variáveis e obter que para  $B \subseteq G$ ,  $B$  boreliano, temos

$$\begin{aligned} P(\vec{Y} \in B) &= P(\vec{X} \in H^{-1}(B)) \\ &= \int \cdots \int_{H^{-1}(B)} f(x_1, \dots, x_n) dx_1 \cdots dx_n \\ &= \int \cdots \int_B f(H_1^{-1}(y_1, \dots, y_n), \dots, H_n^{-1}(y_1, \dots, y_n)) |J| dy_1 \cdots dy_n. \end{aligned}$$

## Jacobiano de uma Função

Como  $P(\vec{Y} \in G) = P(\vec{X} \in H^{-1}(G)) = P(\vec{X} \in G_0) = 1$ , temos que para todo boreliano  $B$  no  $\mathbb{R}^n$ ,

$$\begin{aligned} P(\vec{Y} \in B) &= P(\vec{Y} \in B \cap G) \\ &= \int \cdots \int_{B \cap G} f(H_1^{-1}(y_1, \dots, y_n), \dots, H_n^{-1}(y_1, \dots, y_n)) |J| dy_1 \cdots dy_n. \end{aligned}$$

Esta última integral é igual a integral sobre o conjunto  $B$  da função que toma o valor

$$f(H_1^{-1}(y_1, \dots, y_n), \dots, H_n^{-1}(y_1, \dots, y_n)) |J|,$$

para  $\vec{y} \in G$ , e zero no caso contrário. Portanto, pela definição de densidade temos que

$$f_{\vec{Y}}(y_1, \dots, y_n) = \begin{cases} f(H_1^{-1}(y_1, \dots, y_n), \dots, H_n^{-1}(y_1, \dots, y_n)) |J|, \\ \text{se } \vec{y} \in G, \\ 0, \text{ caso contrário.} \end{cases}$$

# Jacobiano de uma Função

## Observação

- (a) Note que  $J$  é o Jacobiano da função inversa  $H^{-1}$ , em alguns casos pode ser útil obter  $J$  a partir do Jacobiano  $J'$  da função  $H$  através da relação

$$J = \frac{1}{J'}|_{\vec{x}=H^{-1}(\vec{y})}.$$

- (b) Para obter a distribuição de  $\vec{Y} = H(\vec{X})$  quando a dimensão de  $\vec{Y}$  é menor que a dimensão de  $\vec{X}$  muitas vezes é possível definir outras variáveis aleatórias  $Y'_1, \dots, Y'_m$ , utilizar o método do Jacobiano para determinar a densidade conjunta de  $\vec{Y}, Y'_1, \dots, Y'_m$  e, finalmente, obter a densidade marginal conjunta de  $\vec{Y}$ . Considere o seguinte exemplo:

# Jacobiano de uma Função

## Observação

### Exemplo 4

Suponha que  $X_1, X_2$  tem densidade conjunta dada por  $f(x, y)$  e que estamos interessados na distribuição de  $Y_1 = X_1^2 + X_2$ . Como esta não é uma transformação 1-1, ela não possui inversa. Vamos definir uma nova variável  $Y_2 = X_1$  de modo que a função  $(Y_1, Y_2) = H(X_1, X_2) = (X_1^2 + X_2, X_1)$  possua uma função inversa diferenciável,  $(X_1, X_2) = H^{-1}(Y_1, Y_2) = (Y_2, Y_1 - Y_2^2)$ . Deste modo temos que

$$J = \det \begin{pmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} \end{pmatrix} = \begin{pmatrix} 0 & 1 \\ 1 & -2y_2 \end{pmatrix} = -1$$

Então temos que,  $f_{Y_1, Y_2}(y_1, y_2) = f(y_2, y_1 - y_2^2)$ . Finalmente, para encontrarmos  $f_{Y_1}$  integramos sobre todos os possíveis valores da variável  $Y_2$  que introduzimos:

$$f_{Y_1} = \int_{-\infty}^{\infty} f(y_2, y_1 - y_2^2) dy_2.$$

# Jacobiano de uma Função

## Observação

- (c) Podemos utilizar o método do Jacobiano em outros casos em que a função  $H$  não é 1-1. Para tanto, suponha que  $G, G_1, \dots, G_k$  sejam subregiões abertas do  $\mathbb{R}^n$  tais que  $G_1, \dots, G_k$  sejam disjuntas e  $P(\vec{X} \in \cup_{i=1}^k G_i) = 1$ , tais que a função  $H|_{G_l}$ , a restrição de  $H$  a  $G_l$ , seja um correspondência 1-1 entre  $G_l$  e  $G$ , para  $l = 1, \dots, k$ . Suponha que para todo  $l$ , a função inversa de  $H|_{G_l}$  satisfaça as hipóteses do caso anterior, e seja  $J_l$  o Jacobiano da inversa de  $H|_{G_l}$ . Pode-se provar que

$$f_{\vec{Y}}(y_1, \dots, y_n) = \begin{cases} \sum_{l=1}^k f(H|_{G_l}^{-1}(y_1, \dots, y_n)) |J_l|, \\ \text{se } \vec{y} \in G, \\ 0, \text{ caso contrário.} \end{cases}$$