

Valor Esperado

Temos ainda um elemento central e fundamental para a teoria da probabilidade que precisamos abordar. Este é o conceito de *esperança* ou *valor esperado*.

Intuitivamente, o valor esperado de uma variável aleatória X é a generalização do conceito de média ponderada dos valores que X assume ou equivalentemente, de modo mais geométrico, o centro de massa dos valores que X assume.

Como motivação considere X é uma variável simples dada por

$$X = \sum_{k=1}^n a_k \cdot \mathbb{1}_{A_k},$$

com A_1, A_2, \dots, A_n disjuntos. Então a média ponderada $m(X)$ dos valores que X assume é

$$m(X) = \sum_{k=1}^n a_k \mathbf{P}(A_k) = \int X \, d\mathbf{P}.$$

o que motiva a definição:

7.1 DEFINIÇÃO (VALOR ESPERADO OU ESPERANÇA) Se X é uma variável aleatória definida em $(\Omega, \mathcal{F}, \mathbf{P})$, seu *valor esperado*, *esperança* ou *média* é definido como

$$\mathbf{E}[X] := \int_{\Omega} X \, d\mathbf{P}$$

Usaremos aqui a mesma nomenclatura usada em integrais de Lebesgue, e diremos que X é **integrável** se $\mathbf{E}|X| < \infty$ (o que é equivalente a dizer que $\mathbf{E}[X^+] < \infty$ e $\mathbf{E}[X^-] < \infty$ e de

modo mais geral falaremos em esperança de X se X for quasi-integrável, isto é se $\mathbf{E}[X^+]$ ou $\mathbf{E}[X^-]$ for finita.

Agora podemos retomar o exemplo de variáveis aleatórias simples de posse da definição da esperança

7.2 EXEMPLO (VARIÁVEIS ALEATÓRIAS SIMPLES) *Seja X uma variável aleatória X dada por*

$$X = \sum_{k=1}^n a_k \cdot \mathbb{1}_{A_k},$$

com A_1, A_2, \dots, A_n disjuntos. Então

$$\mathbf{E}[X] = \int X \, d\mathbf{P} = \sum_{k=1}^n a_k \mathbf{P}(A_k).$$

Se além disso, os valores $a_1, \dots, a_n \in \mathbb{R}$ são distintos, então $A_k = X^{-1}(\{a_k\}) = \{X = a_k\}$, e

$$\mathbf{E}[X] = \sum_{k=1}^n a_k \mathbf{P}(X = a_k).$$

Podemos restringir o exemplo anterior é obter um dos exemplos mais simples e também um dos mais úteis.

7.3 EXEMPLO (A ESPERANÇA DA FUNÇÃO INDICADORA) *Seja $\mathbb{1}_A$ a indicadora de um eventos $A \in \mathcal{F}$. $\mathbb{1}_A$ é uma variável aleatória simples, e pelo exemplo anterior, o seu valor esperado é dado por*

$$\mathbf{E}[\mathbb{1}_A] = \mathbf{P}(A).$$

Ao ser definida como a integral de Lebesgue, a esperança herda uma série de propriedades importantes, que listaremos a seguir.

7.4 TEOREMA *Suponha que X, Y sejam variáveis aleatórias integráveis. Então*

- 1** (Linearidade) $\mathbf{E}[aX + bY] = a\mathbf{E}[X] + b\mathbf{E}[Y]$ para quaisquer números reais a, b .
- 2** Se $X \equiv b \in \mathbb{R}$, constante, então $\mathbf{E}[X] = b$ (escrevemos também que $\mathbf{E}[b] = b$).
- 3** Se $X \geq 0$ então $\mathbf{E}[X] \geq 0$.
- 4** (Monotonicidade) Se $X \geq Y$ então $\mathbf{E}[X] \geq \mathbf{E}[Y]$.
- 5** (Desigualdade triangular) $|\mathbf{E}[X]| \leq \mathbf{E}[|X|]$
- 6** Se $X_n \uparrow X$ então $\mathbf{E}[X] = \lim_{n \rightarrow \infty} \mathbf{E}[X_n]$

Demonstração. Essas propriedades são herança direta das propriedades das integrais de Lebesgue, e não serão demonstradas.

Mostraremos apenas a propriedade 2, que é típica de medidas de probabilidade.

Tome então uma variável aleatória X constante igual a b . Ou seja, $X(\omega) = b$ para todo ω . Essa variável é uma variável simples, dada por

$$X = b \cdot \mathbb{1}_\Omega,$$

e portanto

$$\mathbf{E}[b] = \mathbf{E}[X] = b \cdot \mathbf{P}(\Omega) = b.$$

7.5 EXEMPLO Se uma esfera é colorida de modo que 90% de sua área seja vermelha e 10% seja azul, então existe um modo de inscrever um cubo de modo que os 8 vértices estejam tocando pontos vermelhos da esfera.

Sejam X_1, \dots, X_8 as variáveis aleatórias indicadoras do fato de cada vértice ser vermelho ou não. Então, claramente $X_1 + \dots + X_8$ é o número de vértices vermelhos. Por linearidade da esperança,

$$\mathbf{E}[X_1 + \dots + X_8] = \mathbf{E}[X_1] + \dots + \mathbf{E}[X_8] = 8 \cdot 0.9 = 7.2.$$

Para que o número médio de vértices seja 7.2, deve haver algum cubo com mais de 7 vértices vermelhos, e portanto deve ter 8 vértices vermelhos.

Esse é um exemplo da utilização de técnicas probabilísticas para provar fatos determinísticos.

Observe que não exigimos que as variáveis sejam independentes. Verifique que de fato isso não é necessário. \triangleleft

Temos também a seguinte caracterização do operador esperança.

7.6 TEOREMA (CARACTERIZAÇÃO DA ESPERANÇA) A esperança é o único operador $\mathbf{E} : \mathcal{L}^1(\Omega) \rightarrow \mathbb{R}$ que satisfaz:

- Linearidade. Para $a, b \in \mathbb{R}$, $\mathbf{E}[aX + bY] = a\mathbf{E}[X] + b\mathbf{E}[Y]$.
- Continuidade. Se $X_n \rightarrow X$ então $\mathbf{E}[X_n] \rightarrow \mathbf{E}[X]$
- Relação com a probabilidade. Para cada evento A , $\mathbf{E}[\mathbb{1}_A] = \mathbf{P}(A)$.

Demonstração. Veja que

$$\mathbf{E}_1[X] := \int_{\Omega} X d\mathbf{P}$$

tem as propriedades pedidas. Assim temos trivialmente a existência.

Vamos provar a unicidade mostrando a coincidência de um operador \mathbf{E} com as propriedades listadas e \mathbf{E}_1 .

O item 3. e a linearidade nos permite mostrar a coincidência para funções simples.

Se $X = \sum_i a_i \mathbb{1}_{A_i}$ então $\mathbf{E}_1[X] = \sum_i a_i \mathbf{P}(A_i) = \mathbf{E}[X]$.

Provaremos agora para funções positivas. Dado $X > 0$, temos que existem funções simples X_n com $X_n \uparrow X$. Por continuidade

$$\mathbf{E}_1[X] = \lim \mathbf{E}_1[X_n] = \lim \mathbf{E}[X_n] = \mathbf{E}[X]$$

Para funções quaisquer. Consideramos a decomposição $X = X^+ + X^-$ e usamos a linearidade

antes de darmos continuidade, vamos estabelecer uma nomenclatura que será central deste ponto em diante.

7.7 DEFINIÇÃO Dada um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbf{P})$, diremos que uma afirmativa \mathbb{A} ocorre *quase-certamente* se

$$\mathbf{P}(\{\omega \in \Omega : \omega \text{ satisfaz a afirmativa } \mathbb{A}\}) = 1.$$

De notaremos isso por “ \mathbb{A} ocorre q.c.”.

Em particular, dadas duas variáveis aleatórias X, Y definidas em Ω , temos que $X = Y$ q.c., se $\mathbf{P}(X = Y) = 1$. Ou ainda que $X \leq Y$ q.c se $\mathbf{P}(X \leq Y) = 1$.

Integrais de Lebesgue ignoram eventos de medida nula, e isso é mostrado no seguinte resultado.

7.8 PROPOSIÇÃO Dadas variáveis aleatórias X e Y , vale que

- 1** Se $X = 0$ q.c então $\mathbf{E}[X] = 0$;
- 2** Se $X = Y$ q.c e X é integrável ou $\mathbf{E}[X] = \pm\infty$, então $\mathbf{E}[Y] = \mathbf{E}[X]$;
- 3** Se $X \leq Y$ q.c. e Y é integrável, então $\mathbf{E}[X] \leq \mathbf{E}[Y]$ ($\mathbf{E}[X]$ pode ser $-\infty$).
- 4** Se $X \geq 0$ e $\mathbf{E}[X] = 0$, então $X = 0$ q.c..

Demonstração.

- 1** Suponha que X é simples. Temos então que

$$X = \sum_{k=1}^n a_k \mathbb{1}_{A_k},$$

e como $\mathbf{P}(X = 0) = 1$, então $\mathbf{P}(A_k) = 0$ sempre que $a_k \neq 0$. Com isso, temos que $\mathbf{E}[X] = 0$.

Para X não negativa, tome $(X_n)_{n \geq 1}$ uma sequência não-decrescente de variáveis aleatórias simples e não-negativas tal que $X_n \uparrow X$. Como $0 \leq X_n \leq X$ e $\mathbf{P}(X = 0) = 1$, temos que $X_n = 0$ q.c. e portanto $\mathbf{E}[X_n] = 0$. Assim, pelo Teorema da Convergência Monótona, $\mathbf{E}[X] = \lim_{n \rightarrow \infty} \mathbf{E}[X_n] = 0$.

Para X qualquer, basta notar que se $X = 0$ q.c., então $X^+ = 0$ q.c. e $X^- = 0$ q.c..

2 Exercício (aplique o item anterior em $X - Y$)

3 Tome X, Y variáveis aleatórias tais que $X \leq Y$ q.c. e Y integrável. Defina

$$X^* = X \cdot \mathbb{1}_{X \leq Y} + Y \cdot \mathbb{1}_{X > Y}.$$

Como $\mathbf{P}(X > Y) = 0$, então $X^* = X$ q.c., e além disso $X^* \leq Y$ pontualmente.

Se X^* é integrável, então a monotonicidade da esperança nos dá que $\mathbf{E}[X^*] \leq \mathbf{E}[Y]$, e pelo item anterior $\mathbf{E}[X] = \mathbf{E}[X^*] \leq \mathbf{E}[Y]$.

Caso contrário, temos $(X^*)^+ \leq Y^+$, de modo que $\mathbf{E}(X^*)^+ \leq \mathbf{E}[Y^+] < \infty$ e $\mathbf{E}[(X^*)^-] = \infty$, de modo que $\mathbf{E}[X^*] = -\infty$.

Agora basta usar o item anterior para X^+ e X^- para concluir o resultado.

4 Dado $\epsilon > 0$, defina $Y_\epsilon = \epsilon \mathbb{1}_{\{X > \epsilon\}}$ e observe que $Y_\epsilon \leq X$ para todo $\epsilon > 0$. Segue que

$$\epsilon \mathbf{P}(X > \epsilon) = \mathbf{E}[Y_\epsilon] \leq \mathbf{E}[X] = 0,$$

e portanto $\mathbf{P}(X > \epsilon) = 0$ para todo $\epsilon > 0$.

Fazendo $\epsilon \rightarrow 0$, vemos que $\mathbf{P}(X > 0) = 0$, e como $\mathbf{P}(X \geq 0) = 1$, o resultado segue. \square

7.1 Calculando a Esperança

Nesta seção veremos como a esperança de uma variável aleatória pode ser determinada a partir de sua distribuição. Para isso, vamos seguir a estratégia de três passos, mas de um ponto de vista bem específico.

Tome agora uma variável aleatória X qualquer, e $\phi : \mathbb{R} \rightarrow \mathbb{R}$ uma função mensurável e simples e não-negativa, dada por

$$\phi(x) = \sum_{k=1}^n a_k \mathbb{1}_{A_k}(x),$$

$A_1, \dots, A_n \in \mathcal{B}(\mathbb{R})$ disjuntos.

Temos assim que

$$\phi(X) = \sum_{k=1}^n a_k \mathbb{1}_{A_k}(X) = \sum_{k=1}^n a_k \mathbb{1}_{X \in A_k},$$

que é uma variável aleatória simples.

Segue que

$$\mathbf{E}[\phi(X)] = \sum_{k=1}^n a_k \mathbf{P}(X \in A_k) = \sum_{k=1}^n a_k \mathbf{P}_X(A_k) = \int_{\mathbb{R}} \phi(x) d\mathbf{P}_X(x).$$

Dada agora uma função $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ mensurável e não negativa, tome uma sequência não-decrescente de funções simples e mensuráveis $\phi_n : \mathbb{R} \rightarrow \mathbb{R}, n \geq 1$, não-negativas e tais que $\phi_n(x) \uparrow \varphi(x)$, para todo $x \in \mathbb{R}$.

Pelos mesmos argumentos anteriores, $\phi_n(X), n \geq 1$ é uma sequência de variáveis aleatórias simples e não-negativas, tais que $\phi_n(X) \uparrow \varphi(X)$.

Segue do Teorema da Convergência Monótona, que

$$\mathbf{E}[\varphi(X)] = \lim_{n \rightarrow \infty} \mathbf{E}[\phi_n(X)] = \lim_{n \rightarrow \infty} \int_{\mathbb{R}} \phi_n(x) d\mathbf{P}_X(x) = \int_{\mathbb{R}} \varphi(x) d\mathbf{P}_X(x).$$

Dada agora uma função $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ mensurável, podemos escrever $\varphi = \varphi^+ - \varphi^-$, e aplicando o que descobrimos até agora, vemos que

$$\mathbf{E}[\varphi(X)] = \mathbf{E}[\varphi^+(X)] - \mathbf{E}[\varphi^-(X)] = \int_{\mathbb{R}} \varphi^+(x) d\mathbf{P}_X(x) - \int_{\mathbb{R}} \varphi^-(x) d\mathbf{P}_X(x) = \int_{\mathbb{R}} \varphi(x) d\mathbf{P}_X(x).$$

Com isso mostramos que

7.9 TEOREMA (TEOREMA DA MUDANÇA DE VARIÁVEIS) Dada uma variável aleatória X definida em um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbf{P})$ com distribuição \mathbf{P}_X , e uma função mensurável $\varphi : \mathbb{R} \rightarrow \mathbb{R}$, então

$$\mathbf{E}[\varphi(X)] = \int_{\mathbb{R}} \varphi(x) d\mathbf{P}_X(x).$$

Ou seja, se qualquer um dos lados da equação acima estiver bem definido, o outro também está e a igualdade vale.

Em particular

$$\mathbf{E}[X] = \int_{\mathbb{R}} x d\mathbf{P}_X(x)$$

Uma consequência direta do resultado anterior é a seguinte.

7.10 COROLÁRIO (DISTRIBUIÇÃO DETERMINA A ESPERANÇA) Dado X integrável então se $X \stackrel{d}{=} Y$ então Y é integrável e $\mathbf{E}[X] = \mathbf{E}[Y]$.

Agora que sabemos que a esperança de uma variável aleatória é determinada unicamente pela sua distribuição, falta apenas entender como surgem aquelas expressões para variáveis discretas e absolutamente contínuas.

Variáveis Aleatórias Discretas

Vamos lembrar que uma variável aleatória discreta é aquela que assume uma quantidade enumerável de valores. Ou seja, existe um conjunto $S = \{x_1, x_2, \dots\}$ tal que $\mathbf{P}(X \in S) = 1$.

Com isso, temos que a distribuição \mathbf{P}_X é totalmente definida pelos valores de $\mathbf{P}(\{x_k\}) = \mathbf{P}(X = x_k)$.

De fato, para qualquer $A \in \mathcal{B}(\mathbb{R})$

$$\mathbf{P}_X(A) = \sum_{k: x_k \in A} \mathbf{P}_X(\{x_k\}).$$

Perceba também que

$$X = \sum_{k=1}^{\infty} x_k \mathbb{1}_{A_k},$$

onde $A_k = \{X = x_k\} \in \mathcal{F}$.

Para simplificar nossa vida, suponha que $X \geq 0$. Ou seja $x_k \geq 0$ para todo $k \geq 1$. Nestas condições, as variáveis

$$X_n = \sum_{k=1}^n x_k \mathbb{1}_{A_k},$$

são simples e portanto

$$\mathbf{E}[X_n] = \sum_{k=1}^n x_k \mathbf{P}(A_k) = \sum_{k=1}^n x_k \mathbf{P}(X = x_k).$$

Além disso, temos que $X_n \uparrow X$ e o Teorema da Convergência Monótona nos diz que

$$\mathbf{E}[X] = \lim_{n \rightarrow \infty} \mathbf{E}[X_n] = \sum_{k=1}^{\infty} x_k \mathbf{P}(X = x_k).$$

Deixamos como exercício o caso onde X não assume apenas valores positivos.

Fica assim (quase) demonstrado então o seguinte resultado.

7.11 PROPOSIÇÃO Para uma variável aleatória discreta X positiva ou integrável, assumindo valores em $\{x_1, x_2, \dots\}$, temos que

$$\mathbf{E}[X] = \sum_{k=1}^{\infty} x_k \mathbf{P}(x = x_k), \quad (7.1)$$

de modo que a série à direita é absolutamente convergente sempre que X for integrável.

Variáveis Absolutamente Contínuas

Vamos recordar que uma variável aleatória é absolutamente contínua se existe uma função mensurável $f : \mathbb{R} \rightarrow \mathbb{R}^+$, conhecida como **função densidade de probabilidade de X** (ou simplesmente densidade de X) tal que

$$\mathbf{P}_X(A) = \mathbf{P}(X \in A) = \int_A f(x) \, d\mu,$$

onde a integral à direita é a integral de Lebesgue (feita em relação à medida de Lebesgue da reta).

Para entender quem é $\mathbf{E}[\varphi(X)]$ devemos primeiro entender como calcular

$$\int_{\mathbb{R}} \varphi(x) \, d\mathbf{P}_X(x).$$

Para isso, tome primeiro uma função simples

$$\phi(x) = \sum_{k=1}^n a_k \mathbb{1}_{A_k},$$

e note que

$$\begin{aligned} \int_{\mathbb{R}} \phi(x) \, d\mathbf{P}_X(x) &= \sum_{k=1}^n a_k \mathbf{P}_X(A_k) \\ &= \sum_{k=1}^n a_k \int_{A_k} f(x) \, d\mu \\ &= \sum_{k=1}^n a_k \int_{\mathbb{R}} \mathbb{1}_{A_k}(x) f(x) \, d\mu \\ &= \int_{\mathbb{R}} \sum_{k=1}^n a_k \mathbb{1}_{A_k}(x) f(x) \, d\mu \\ &= \int_{\mathbb{R}} \phi(x) f(x) \, dx. \end{aligned}$$

Tomando uma sequência de funções simples $\phi_n, n \geq 1$ não negativas, com $\phi_n \uparrow \varphi \geq 0$, concluímos pelo Teorema da Convergência Monótona que

$$\int_{\mathbb{R}} \varphi(x) \, d\mathbf{P}_X(x) = \lim_n \int_{\mathbb{R}} \phi_n(x) \, d\mathbf{P}_X(x) = \lim_n \int_{\mathbb{R}} \phi_n(x) f(x) \, dx = \int_{\mathbb{R}} \varphi(x) f(x) \, dx.$$

E separando uma função mensurável φ em parte positiva e negativa, concluímos o seguinte resultado.

7.12 PROPOSIÇÃO Para variável aleatória absolutamente contínua X com função densidade de probabilidade $f : \mathbb{R} \rightarrow \mathbb{R}^+$, e uma função mensurável $\phi : \mathbb{R} \rightarrow \mathbb{R}$ vale que

$$\mathbf{E}[\phi(X)] = \int_{\mathbb{R}} \phi(x)f(x) \, dx, \quad (7.2)$$

onde um lado da equação está bem definido se, e somente se, o outro também está.

7.2 Funções de Vetores Aleatórios

Nesta seção falaremos brevemente sobre o cálculo da esperança para funções de vetores aleatórios.

Mas especificamente, dado um vetor aleatório $X = (x_1, \dots, x_n)$ definido em um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbf{P})$ e uma função mensurável $\phi : \mathbb{R}^n \rightarrow \mathbb{R}$, queremos entender como calcular $\mathbf{E}[\phi(X_1, \dots, X_n)]$.

Vamos olhar primeiro para a distribuição \mathbf{P}_X do vetor aleatório X . Lembre-se que, de modo análogo a variáveis aleatórias, \mathbf{P}_X é uma medida de probabilidade em $(\mathbb{R}^n, \mathcal{B}(\mathbb{R}^n))$ dada por

$$\mathbf{P}_X(A) = \mathbf{P}((X_1, \dots, X_n) \in A),$$

para $A \in \mathcal{B}(\mathbb{R}^n)$.

De posse da distribuição \mathbf{P}_X podemos recuperar as **distribuições marginais** das variáveis X_k , fazendo

$$\begin{aligned} \mathbf{P}_{X_k}(B) &= \mathbf{P}(X_k \in B) \\ &= \mathbf{P}(X_k \in B; X_j \in \mathbb{R}; j \neq k) \\ &= \mathbf{P}((X_1, \dots, X_n) \in \mathbb{R}^{k-1} \times B \times \mathbb{R}^{n-k}) \\ &= \mathbf{P}_X(\mathbb{R}^{k-1} \times B \times \mathbb{R}^{n-k}). \end{aligned}$$

A relação entre \mathbf{P}_X e as marginais \mathbf{P}_{X_k} pode ser complicada, e em geral precisamos de informações adicionais sobre o vetor para descrevê-la com mais precisão. Uma das situações onde esta relação está bem definida é no caso onde as variáveis X_1, \dots, X_n são independentes. Deixaremos os detalhes para a lista de exercícios.

Voltando ao nosso problema, não é difícil mostrar, usando os mesmos argumentos usados para mostrar o Teorema 7.9, que vale o seguinte resultado.

7.13 TEOREMA Dado um vetor aleatório $X = (X_1, \dots, X_n)$ definido em um espaço de probabilidade $(\Omega, \mathcal{F}, \mathbf{P})$ com distribuição \mathbf{P}_X , e uma função mensurável $\phi : \mathbb{R}^n \rightarrow \mathbb{R}$, então

$$\mathbf{E}[\phi(X_1, \dots, X_n)] = \int_{\mathbb{R}^n} \phi(x_1, \dots, x_n) \, d\mathbf{P}_X(x_1, \dots, x_n).$$

Ou seja, se qualquer um dos lados da equação acima estiver bem definido, o outro também está e a igualdade vale.

No caso em que as variáveis X_1, \dots, X_n são discretas, assumindo valores em S_1, \dots, S_n respectivamente, então o vetor é também simples, assumindo valores em $S_1 \times \dots \times S_n$, e a variável $\phi(X_1, \dots, X_n)$ é discreta, assumindo valores $\phi(x_1, \dots, x_n) \in \phi(S_1 \times \dots \times S_n)$ com probabilidade $\mathbf{P}(X_1 = x_1, \dots, X_n = x_n)$.

Vale então o seguinte resultado.

7.14 PROPOSIÇÃO Dadas variáveis aleatórias X_1, \dots, X_n discretas assumindo valores em S_1, \dots, S_n , respectivamente, e uma função mensurável $\phi : \mathbb{R}^n \rightarrow \mathbb{R}$, então

$$\mathbf{E}[\phi(X_1, \dots, X_n)] = \sum_{x_1 \in S_1} \dots \sum_{x_n \in S_n} \phi(x_1, \dots, x_n) \mathbf{P}(X_1 = x_1, \dots, X_n = x_n),$$

quando os dois lados estiverem bem definidos.

O caso onde X_1, \dots, X_n são absolutamente contínuas é um pouco mais complicado, pois não garante que o vetor X seja absolutamente contínuo. Ou seja, a existência de densidades $f_1, \dots, f_n : \mathbb{R} \rightarrow \mathbb{R}$ não garante a existência de uma função densidade $f : \mathbb{R}^n \rightarrow \mathbb{R}^+$ tal que

$$\begin{aligned} \mathbf{P}_X(A) &= \mathbf{P}((X_1, \dots, X_n) \in A) \\ &= \int_{\mathbb{R}^n} f(x_1, \dots, x_n) d\lambda_n(x_1, \dots, x_n) \\ &= \int_{\mathbb{R}} \dots \int_{\mathbb{R}} f(x_1, \dots, x_n) dx_1 \dots dx_n, \end{aligned}$$

para $A \in \mathcal{B}(\mathbb{R}^n)$, onde λ_n é a medida de Lebesgue em \mathbb{R}^n .

7.15 OBSERVAÇÃO Para $X = (X_1, \dots, X_n)$ é um vetor aleatório absolutamente contínuo, também é usual dizer que as variáveis X_1, \dots, X_n são conjuntamente absolutamente contínuas. \triangleleft

Não vamos entrar em maiores detalhes sobre esse tipo de vetor, mas podemos mostrar que

7.16 PROPOSIÇÃO Para um vetor aleatório absolutamente contínuo X com função densidade de probabilidade $f : \mathbb{R}^n \rightarrow \mathbb{R}^+$, e uma função mensurável $\phi : \mathbb{R}^n \rightarrow \mathbb{R}$ vale que

$$\mathbf{E}[\phi(X)] = \int_{\mathbb{R}} \dots \int_{\mathbb{R}} \phi(x_1, \dots, x_n) f(x_1, \dots, x_n) dx_1 \dots dx_n, \quad (7.3)$$

onde um lado da equação está bem definido se, e somente se, o outro também está.

7.3 Variância, Covariância e Momentos de uma Variável Aleatória

A esperança mede, como já discutimos, o comportamento médio de uma variável aleatória. Uma média, ponderada pelas probabilidades, dos diversos valores assumidos pela variável. Porém, essa a média falha em captar a dispersão dos valores e suas probabilidades.

Para entender isso, vamos ver um exemplo simples.

7.17 EXEMPLO Tome X e Y variáveis aleatórias discretas tais que

$$P(X = -1) = P(X = 1) = \frac{1}{2},$$

e

$$P(Y = -100) = P(Y = -50) = P(Y = 50) = P(Y = 100) = \frac{1}{4}.$$

Calculando, encontramos que $E[X] = E[Y] = 0$, mas a variável aleatória Y assume valores muito mais dispersos em torno da média. \triangleleft

Uma das alternativas que temos para medir essa dispersão é medir uma espécie de “distância média” (usado aqui de forma livre) entre a variável e sua média. É isso que motiva as próximas definições.

É isso que motiva as próximas definições.

7.18 DEFINIÇÃO (MOMENTOS, VARIÂNCIA E COVARIÂNCIA) Se X é uma variável aleatória em $(\Omega, \mathcal{F}, \mathbf{P})$:

□ Dado $n \in \mathbb{N}^*$ e X tal que X^n seja integrável então

$$m_k := E[X^k] \quad M_k := E[|X|^k] \quad \text{para } k = 1, \dots, n$$

são denominados o k -ésimo **momento** e k -ésimo **momento absoluto** de X respectivamente.

□ Se X é quadrado integrável, então

$$\mathbf{Var}[X] := E[(X - E[X])^2]$$

é a variância de X . O número $\sigma := \sqrt{\mathbf{Var}[X]}$ é denominado **desvio padrão** de X .

□ Se X e Y são quadrado integráveis definimos a covariância de X e Y como

$$\mathbf{Cov}[X, Y] := E[(X - E[X])(Y - E[Y])]$$

As variáveis X e Y são ditas não correlacionadas se $\mathbf{Cov}[X, Y] = 0$.

□ o **coeficiente de correlação** de X e Y não constantes por

$$\rho(X, Y) = \frac{\mathbf{Cov}(X, Y)}{\sigma_X \sigma_Y};$$

7.19 PROPOSIÇÃO (PROPRIEDADES DA VARIÂNCIA E COVARIÂNCIA) Dadas X e Y variáveis aleatórias integráveis. Então:

1 $\text{Var}[X] \geq 0$

2 $\text{Var}[X] = \mathbf{E}[X^2] - \mathbf{E}[X]^2$.

3 $\text{Var}[X] = 0 \iff X = \mathbf{E}[X]$ quase certamente.

4 A aplicação $f : \mathbb{R} \rightarrow \mathbb{R}, x \mapsto \mathbf{E}[(X - x)^2]$ tem um mínimo em $\mathbf{E}[X]$ com $f(\mathbf{E}[X]) = \text{Var}[X]$.

5 $\text{Var}[aX + b] = a^2 \text{Var}[X]$ para $a, b \in \mathbb{R}$.

6 $\text{Cov}[X, Y] = \mathbf{E}[XY] - \mathbf{E}[X]\mathbf{E}[Y]$.

7 $\text{Var}[X + Y] = \text{Var}[X] + \text{Var}[Y] + 2\text{Cov}[X, Y]$

8 $\text{Cov}[X, X] = \text{Var}[X]$;

Demonstração. **1** Segue direto da definição e das propriedades da esperança, uma vez que $(X - \mathbf{E}[X])^2 \geq 0$;

2 Segue da linearidade da esperança. De fato

$$\begin{aligned} \text{Var}[X] &= \mathbf{E}[(X - \mathbf{E}[X])^2] \\ &= \mathbf{E}[X^2 - 2X\mathbf{E}[X] + \mathbf{E}[X]^2] \\ &= \mathbf{E}[X^2] - 2\mathbf{E}[X]^2 + \mathbf{E}[X]^2 \\ &= \mathbf{E}[X^2] - \mathbf{E}[X]^2. \end{aligned}$$

3 Se $\mathbf{E}[(X - \mathbf{E}[X])^2] = \text{Var}[X] = 0$, então $(X - \mathbf{E}[X])^2 = 0$ q.c., e o resultado segue.

4 Imediato.

5 $\text{Var}[aX + b] = \mathbf{E}[(aX + b)^2] - \mathbf{E}[aX + b]^2 = a^2\mathbf{E}[X^2] + 2ab\mathbf{E}[X] + b^2 - (a^2\mathbf{E}[X]^2 + 2ab\mathbf{E}[X] + b^2) = a^2\text{Var}[X]$.

6 Segue da linearidade da esperança que

$$\begin{aligned} \text{Cov}[X, Y] &= \mathbf{E}[(X - \mathbf{E}[X])(Y - \mathbf{E}[Y])] \\ &= \mathbf{E}[XY - X\mathbf{E}[Y] - Y\mathbf{E}[X] + \mathbf{E}[X]\mathbf{E}[Y]] \\ &= \mathbf{E}[XY] - \mathbf{E}[X]\mathbf{E}[Y]. \end{aligned}$$

7 Segue da linearidade da esperança e dos itens anteriores que

$$\begin{aligned}\text{Var}(X + Y) &= \mathbf{E}[(X + Y)^2] - \mathbf{E}[X + Y]^2 \\ &= \mathbf{E}[X^2 + Y^2 + 2XY] - (\mathbf{E}[X]^2 + \mathbf{E}[Y]^2 + 2\mathbf{E}[X]\mathbf{E}[Y]) \\ &= \text{Var}[X] + \text{Var}[Y] + 2\text{Cov}[X, Y].\end{aligned}$$

8 Segue direto da definição. □

O item **4** nos fornece uma descrição geométrica: imagine que queremos minimizar o erro quadrático médio de uma estimativa x da variável X . Nesse caso a estimativa que minimiza esse erro é a esperança e a variância é o menor valor do erro quadrático médio.

7.20 EXEMPLO Seja $X \in \mathcal{L}^2(\mathbf{P})$ integrável e $Y = aX + b$, com $a, b \in \mathbb{R}$ não nulos. Temos então que $\text{Var}(X) < \infty$, $\mathbf{E}[Y] = a\mathbf{E}[X] + b$ e que $\text{Var}[Y] = \text{Var}[aX + b] = a^2\text{Var}[X]$.

Da mesma forma temos que $\text{Cov}[X, Y] = \mathbf{E}[(X - \mathbf{E}[X])(aX + b - (a\mathbf{E}[X] + b))] = a\text{Var}[X]$.

Segue que

$$\rho(X, Y) = \frac{a\text{Var}[X]}{\sqrt{a^2(\text{Var}[X])^2}} = \text{senal}(a) = \begin{cases} 1; & a > 0 \\ -1; & a < 0 \end{cases}.$$

A covariância a correlação servem para medir o “nível de correlação” entre as variáveis. Nesse exemplo vimos que se $Y = aX + b$ então $\text{Cov}[X, Y]$ tem o mesmo sinal de a e $\rho(X, Y)$ é 1 ou -1 , de acordo com o sinal de a .

7.21 TEOREMA (VARIÁVEIS ALEATÓRIAS INDEPENDENTES SÃO NÃO CORRELACIONADAS) Sejam X, Y são variáveis aleatórias independentes integráveis. Então (XY) é integrável e

$$\mathbf{E}[XY] = \mathbf{E}[X]\mathbf{E}[Y]$$

Em particular, variáveis aleatórias independentes não estão correlacionadas.

Demonstração. Assuma primeiro que as variáveis X e Y sejam simples, de modo que X e Y são discretas assumindo uma quantidade finita de valores cada uma.

Nestas condições XY também toma apenas um número finito de valores, de modo que XY é

integrável e

$$\begin{aligned}
 \mathbf{E}[XY] &= \sum_{i=1}^n \sum_{j=1}^m x_i y_j \mathbf{P}[X = x_i, Y = y_j] \\
 &= \sum_{i=1}^n \sum_{j=1}^m x_i y_j \mathbf{P}[X = x_i] \mathbf{P}[Y = y_j] \quad (\text{pela independência}) \\
 &= \left(\sum_{i=1}^n x_i \mathbf{P}[X = x_i] \right) \left(\sum_{j=1}^m y_j \mathbf{P}[Y = y_j] \right) \\
 &= \mathbf{E}[X] \mathbf{E}[Y].
 \end{aligned}$$

Agora suponha $X, Y \geq 0$, e tome uma sequência crescente $(\phi_n)_{n \geq 0}$ de funções $\phi_n : \mathbb{R}^+ \rightarrow \mathbb{R}^+$ simples, tal que $\phi_n(x) \uparrow x$, para todo $x \in \mathbb{R}^+$.

Para cada $n \geq 1$ defina agora $X_n = \phi_n(X)$ e $Y_n = \phi_n(Y)$.

Como X, Y são independentes, X_n, Y_n são independentes e simples, para cada $n \geq 1$. Além disso, $X_n \uparrow X$ e $Y_n \uparrow Y$. Assim, pelo Teorema da Convergência Monótona, segue que

$$\mathbf{E}[XY] = \lim_{n \rightarrow \infty} \mathbf{E}[X_n Y_n] = \lim_{n \rightarrow \infty} \mathbf{E}[X_n] \mathbf{E}[Y_n] = \mathbf{E}[X] \mathbf{E}[Y] < \infty.$$

Para variáveis quaisquer basta utilizar a decomposição em parte positiva e negativa e observar que as famílias $\{X^+, Y^+\}$, $\{X^+, Y^-\}$, $\{X^-, Y^+\}$ e $\{X^-, Y^-\}$ são formadas por variáveis independentes. \square

Vimos assim que variáveis independentes tem realmente covariância nula. Mas a recíproca não é verdadeira. Vamos deixar esse fato como exercício.

Exercício: Dê um exemplo de variáveis X e Y dependentes, mas com $\mathbf{Cov}[X, Y] = 0$.

(Dica: tente pensar em uma variável X com $\mathbf{E}[X] = 0$ e uma variável Y tal que $Y = 0$ sempre que $X \neq 0$.) \square

Uma outra consequência importante é sobre a variância da soma de variáveis independentes.

7.22 COROLÁRIO Se X_1, \dots, X_n são variáveis aleatórias independentes, então

$$\mathbf{Var}[X_1 + \dots + X_n] = \mathbf{Var}[X_1] + \dots + \mathbf{Var}[X_n].$$

Demonstração. Para $n = 2$ temos

$$\mathbf{Var}[X_1 + X_2] = \mathbf{Var}[X_1] + \mathbf{Var}[X_2] + 2\mathbf{Cov}[X_1, X_2] = \mathbf{Var}[X_1] + \mathbf{Var}[X_2].$$

Os demais casos segue por indução. \square

7.23 PROPOSIÇÃO A aplicação $\text{Cov} : \mathcal{L}^2(\mathbf{P}) \times \mathcal{L}^2(\mathbf{P}) \rightarrow \mathbb{R}$ é uma forma simétrica bilinear positiva semidefinida e $\text{Cov}[X, Y] = 0$ se Y é constante quase certamente.

Demonstração. A demonstração é direta e será deixada como exercício. \square

7.24 PROPOSIÇÃO (DESIGUALDADE DE CAUCHY-SCHWARZ) Se $X, Y \in \mathcal{L}^2(\mathbf{P})$, então

$$\text{Cov}[X, Y]^2 \leq \text{Var}[X]\text{Var}[Y].$$

A igualdade é válida se, e somente se, existirem $a, b, c \in \mathbb{R}$, não todas nulas, e tais que $aX + bY + c = 0$ q.c.

Demonstração. A desigualdade de Cauchy-Schwarz é verdadeira para qualquer forma bilinear positiva semidefinida e, portanto, em particular para a covariância. Ainda assim, faremos uma demonstração aqui para deixar o texto mais completo e auto-contido.

Faremos a demonstração supondo que $\text{Var}[Y] > 0$. O caso no qual $\text{Var}[Y] = 0$ será deixada como exercício.

Dada $\text{Var}[Y] > 0$, seja $\theta := -\frac{\text{Cov}[X, Y]}{\text{Var}[Y]}$.

Temos assim $\theta \text{Var}[Y] = -\text{Cov}[X, Y]$, e portanto

$$\begin{aligned} 0 &\leq \text{Var}[X + \theta Y]\text{Var}[Y] \\ &= (\text{Var}[X] + 2\theta \text{Cov}[X, Y] + \theta^2 \text{Var}[Y])\text{Var}[Y] \\ &= \text{Var}[X]\text{Var}[Y] - \text{Cov}[X, Y]^2. \end{aligned}$$

Note que $\text{Var}[X + \theta Y] = 0$ se, e somente se, $X + \theta Y$ for constante quase certamente.

Com isso, como supomos $\text{Var}[Y] \neq 0$, segue que a igualdade na primeira inequação acima vale se, e somente se, $X + \theta Y$ for constante quase certamente. \square

7.25 COROLÁRIO Dadas variáveis $X, Y \in \mathcal{L}^2(\mathbf{P})$ então

$$|\rho(X, Y)| \leq 1,$$

com igualdade apenas se existirem constantes $a, b, c \in \mathbb{R}$, não todas nulas, tais que $aX + bY + c = 0$.

7.4 Integração com respeito à Distribuição

Nesta seção, definimos integrais em relação às funções de distribuição. Essas integrais, conhecidas como **integrais de Lebesgue-Stieltjes**, podem ser definidas a partir do zero, mas no entanto, elas são simplesmente as integrais com respeito a probabilidades induzidas em \mathbb{R} . Nossa principal aplicação ao cálculo de esperanças.

7.26 DEFINIÇÃO Dado uma função de distribuição F em \mathbb{R} , existe uma única probabilidade \mathbf{P}_F em $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ tal que $\mathbf{P}_F((a, b]) = F(b) - F(a)$ para todo intervalo $(a, b]$.

A demonstração desse fato é análoga a construção que fizemos na seção 2.4 da Integral de Lebesgue e foi feita no exercício 2.3.

7.27 DEFINIÇÃO (INTEGRAÇÃO COM RESPEITO À DISTRIBUIÇÃO) Dada F uma função de distribuição em \mathbb{R} . Para toda função $g \in \mathcal{L}^1(\mathbf{P}_F)$ definimos a integral de g com respeito a F

$$\mathbf{E}_F[g] := \int_{\mathbb{R}} g(x) dF(x)$$

onde estamos considerando g como uma variável aleatória no espaço de probabilidade $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbf{P}_F)$.

7.28 PROPOSIÇÃO Se $F(t) = \sum p_i \mathbb{1}_{(t_i \leq t)}$ então para toda $g \geq 0$

$$\mathbf{E}_F[g] = \int_{\mathbb{R}} g dF = \sum_i p_i g(t_i).$$

Demonstração. Para provar esse fato suponha que $g = \sum_{j=1}^m b_j \mathbb{1}_{B_j}$ é uma função aleatória simples.

$$\mathbf{E}_F[g] := \sum_{j=1}^m b_j \mathbf{P}_X(B_j) = \sum_{j=1}^m b_j \sum_i p_i \mathbb{1}_{t_i \in B_j} \quad (7.4)$$

$$= \sum_i p_i \sum_{j=1}^m b_j \mathbb{1}_{B_j}(t_i) \quad (7.5)$$

$$= \sum_i p_i g(t_i) \quad (7.6)$$

Para provar para as funções mensuráveis $g \geq 0$ basta utilizar o Teorema da Convergência Monótona. Se $g \geq 0$ e $g_n \uparrow g$

$$\mathbf{E}_F[g] = \lim_{n \rightarrow \infty} \mathbf{E}_F[g_n] = \lim_{n \rightarrow \infty} \sum_i p_i g_n(t_i) = \sum_i p_i g(t_i)$$

7.29 PROPOSIÇÃO Suponha que F é absolutamente contínua com densidade contínua por partes f . Então se g é positiva e contínua por partes

$$\mathbf{E}_F[g] = \int_{\mathbb{R}} g dF = \int_{-\infty}^{\infty} g(x) f(x) dx$$

Demonstração. Para provar esse fato suponha que $g = \sum_{j=1}^m b_j \mathbb{1}_{B_j}$ é uma função aleatória do tipo escada. Então

$$\mathbf{E}_F[g] := \sum_{j=1}^m b_j \mathbf{P}(B_j) = \sum_{j=1}^m b_j \int_{B_j} f(x) dx \quad (7.7)$$

$$= \sum_{j=1}^m b_j \int_{-\infty}^{\infty} f(x) \mathbb{1}_{B_j} dx \quad (7.8)$$

$$= \int_{-\infty}^{\infty} f(x) \left[\sum_{j=1}^m b_j \mathbb{1}_{B_j} \right] dx \quad (7.9)$$

$$= \int_{-\infty}^{\infty} f(x) g(x) dx \quad (7.10)$$

A demonstração para uma função geral $g > 0$ segue, aproximando g por funções escadas, o que é possível porque g é contínua por partes e, em seguida, usando o Teorema de Convergência Monótona. \square

Utilizando as Proposições 7.28 e 7.29 podemos integrar com respeito a uma distribuição que seja combinação de uma discreta e uma absolutamente contínua.

7.30 TEOREMA (MUDANÇA DE VARIÁVEIS) Dada uma variável aleatória $X \in \mathcal{L}^1$ e F_X a função de distribuição de X então

$$\mathbf{E}[X] = \int_{\mathbb{R}} x dF_X(x)$$

e de modo mais geral,

$$\mathbf{E}[g(X)] = \int_{\mathbb{R}} g(x) dF_X(x).$$

Demonstração. Provaremos primeiro para funções simples não negativas $X = \sum_{i=1}^n a_i \mathbb{1}_{A_i}$. Nesse caso $\mathbf{E}[X] = \sum_{i=1}^n a_i \mathbf{P}(A_i)$. Por outro lado $F_X(t) = \sum_i \mathbf{P}(A_i) \mathbb{1}_{a_i \leq t}$ de modo que

$$\int_{\mathbb{R}} x dF_X(x) = \sum_{i=1}^n a_i \mathbf{P}(A_i)$$

Deixaremos o restante da demonstração, que segue a estratégia usual de 3 passos, como exercício.

7.31 EXEMPLO Se $X \sim \mathcal{N}(0; 1)$ então $\mathbf{E}(X) = 0$.

$$\mathbf{E}[X] = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} x e^{-\frac{x^2}{2}} dx = -\frac{1}{\sqrt{2\pi}} \int_{*}^{*} e^u du = -\frac{1}{\sqrt{2\pi}} e^{-x^2/2} \Big|_{-\infty}^{\infty} = 0.$$

7.32 EXEMPLO Se $X \sim \text{Exp}(\lambda)$ então $\mathbf{E}[X^n] = \frac{n!}{\lambda^n}$. \triangleleft